

Entropy-Based Network Intrusion Detection using Markov Chains

**Ανίχνευση Εισβολών Δικτύου βάσει Εντροπίας με
χρήση Μαρκοβιανών Αλυσίδων**

Ιγνάτιος Μαυρέλης

22031

ece22031@go.uop.gr

Επιβλέπων Καθηγητής: Παναγιώτης Ζέρβας

Τμήμα Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών

Πανεπιστήμιο Πελοποννήσου

23 Σεπτεμβρίου 2026

Περίληψη

Η ραγδαία εξέλιξη των δικτυακών απειλών καθιστά τις παραδοσιακές μεθόδους ανίχνευσης, οι οποίες βασίζονται κυρίως σε στατικές υπογραφές, όλο και λιγότερο αποτελεσματικές. Η συγκεκριμένη αναφορά παρουσιάζει τον σχεδιασμό, την υλοποίηση και την αξιολόγηση ενός συστήματος ανίχνευσης ανωμαλιών δικτύου βασισμένη στα μεταδεδομένα. Αντί να λειτουργεί ελέγχοντας για γνωστές επιθέσεις (ως Deep Packet Inspection - DPI), προσεγγίζει το πρόβλημα από τη σκοπιά της ανάλυσης συμπεριφοράς μέσω των μεταδεδομένων της κίνησης, δημιουργώντας ένα προφίλ φυσιολογικής δικτυακής συμπεριφοράς. Χρησιμοποιώντας θεωρητικές προσεγγίσεις από τη Θεωρία Πληροφορίας, όπως η εντροπία Shannon, σε συνδυασμό με Μαρκοβιανές αλυσίδες πρώτης τάξης ($k = 1$), το σύστημα παρακολουθεί τη ροή της κίνησης και εντοπίζει αποκλίσεις χωρίς καμία απολύτως γνώση για τη μορφή του ωφέλιμου payload. Η αρχιτεκτονική του πλαισιώνεται από πολλαπλούς αισθητήρες (Multi-Sensor Fusion) οι οποίοι λειτουργούν ταυτόχρονα, μειώνοντας δραματικά τα σφάλματα και προσφέροντας απόλυτη επεξηγησιμότητα, σε αντίθεση με τα σύγχρονα «μαύρα κουτιά» των Νευρωνικών Δικτύων (Goodfellow et al., 2016).

Λέξεις-κλειδιά: Network Intrusion Detection, Shannon Entropy, Markov Chains, Unsupervised Learning, Multi-Sensor Fusion, Cybersecurity, Data Discretization, Deterministic Algorithms

Περιεχόμενα

1	Εισαγωγή	3
1.1	Εισαγωγή και Ορισμός Προβλήματος	3
1.2	Στόχοι της Εργασίας	3
1.3	Δομή της Αναφοράς	4
2	Θεωρητικό Υπόβαθρο και Βιβλιογραφική Επισκόπηση	4
2.1	Θεωρία Διακριτών Πηγών και Εντροπία	4
2.2	Μοντελοποίηση Στοχαστικών Διαδικασιών	4
2.3	Επισκόπηση της Βιβλιογραφίας και Διαφορετικές Προσεγγίσεις	5
2.4	Συμπεράσματα και Κατεστημένο (State of the Art)	6
2.5	Συγκριτική Ανάλυση Μεθόδων	6
2.6	Αξιολόγηση Αποκλίσεων (Cross-Entropy)	6
3	Μεθοδολογία	7
3.1	Περιγραφή Συνόλου Δεδομένων	7
3.2	Επιλογή Χαρακτηριστικών και Μηχανική Δεδομένων	8
3.3	Διακριτοποίηση και Εξομάλυνση	8
3.4	Αρχιτεκτονική Μοντέλου και Διαδικασία "Εκπαίδευσης"	9
4	Υλοποίηση	10
4.1	Περιβάλλον Ανάπτυξης	10
4.2	Αρχιτεκτονική Πολλαπλών Αισθητήρων	10
5	Πειράματα και Αποτελέσματα	11
5.1	Baseline Αποτελέσματα	11
5.2	Γραφική Αξιολόγηση	12
6	Συζήτηση	15
6.1	Ερμηνεία Αποτελεσμάτων	15
6.2	Περιορισμοί Συστήματος	16
6.3	Πρόσθετες Λειτουργίες και Επεκτάσεις (BETA)	16
7	Συμπεράσματα	17
7.1	Σύνοψη Εργασίας	17
7.2	Μελλοντική Εργασία	17
A'	Παράρτημα A: Κώδικας (Code Snippets)	20

Κατάλογος σχημάτων

1	Πτώση της εντροπίας καθώς αυξάνεται η τάξη του μοντέλου (k)	12
2	Κανονικοποιημένη Απόκλιση πολλαπλών αισθητήρων κατά τη διάρκεια επιθέσεων	13
3	Αξιολόγηση απόδοσης (ROC Curves & Confusion Matrix) του μοντέλου	14

Κατάλογος πινάκων

1	Αριθμός Μοναδικών Καταστάσεων και Εντροπία Βάσης Ανάλογα με την Τάξη k του Μοντέλου (Μέγεθος Ακολουθίας: 488,381)	11
---	---	----

1 Εισαγωγή

1.1 Εισαγωγή και Ορισμός Προβλήματος

Στη σύγχρονη εποχή, η κυβερνοασφάλεια αποτελεί έναν από τους πιο κρίσιμους πυλώνες λειτουργίας οργανισμών και κρατικών υποδομών. Ωστόσο, οι παραδοσιακές μέθοδοι ασφάλειας, όπως τα κλασικά συστήματα Firewalls και άλλα Intrusion Prevention Systems, υπολειπονται σημαντικά απέναντι σε Zero-day επιθέσεις. Τα συστήματα αυτά, λειτουργώντας ουσιαστικά ως "ανιχνευτές", βασίζονται στην ύπαρξη **ήδη γνωστών υπογραφών**. Αν η επίθεση είναι καινούργια και δεν υπάρχει στη βάση δεδομένων, περνάει εντελώς απαρατήρητη.

Η παρούσα εργασία προτείνει την ανάπτυξη ενός συστήματος που προσομοιάζει περισσότερο το ανθρώπινο ανοσοποιητικό σύστημα. Ένα τέτοιο Network Behavior Anomaly Detector - NBAD σύστημα δεν χρειάζεται να γνωρίζει εξ αρχής το προφίλ όλων των απειλών. Αντιθέτως, μαθαίνει ενδελεχώς τι σημαίνει «υγιής κατάσταση» για τον συγκεκριμένο οργανισμό, και σημαίνει συναγερμό όταν εντοπίσει μια στατιστικά σημαντική απόκλιση από το φυσιολογικό.

Το πλεονέκτημα αυτής της αρχιτεκτονικής είναι ότι αποφεύγει τον έλεγχο των ίδιων των αρχείων/δεδομένων του χρήστη (DPI). Σήμερα, περίπου το 90% της διαδικτυακής κίνησης είναι κρυπτογραφημένο (μέσω HTTPS/TLS), άρα η ανάγνωση του payload είναι πρακτικά αδύνατη. Η λύση βρίσκεται στα **μεταδεδομένα της κίνησης**, δηλαδή στα χαρακτηριστικά ροής (NetFlow), όπως η χρονική διάρκεια της επικοινωνίας και ο όγκος των δεδομένων.

Μέσω της χρήσης της υπό συνθήκη Εντροπίας, το σύστημα παρακολουθεί τη σταθερότητα των ροών. Σε κατάσταση ηρεμίας, ένα δίκτυο έχει μια προβλέψιμη, σχετικά υψηλή εντροπία που δηλώνει ποικιλομορφία κίνησης (πολλοί χρήστες, διαφορετικές σελίδες). Όταν όμως εκδηλωθεί μια απειλή, για παράδειγμα μια επίθεση Άρνησης Εξυπηρέτησης (DDoS) ή σάρωσης θυρών (Port Scanning), χιλιάδες πανομοιότυπα πακέτα στέλνονται μαζικά. Αυτή η μηχανική επανάληψιμότητα προκαλεί βίαιη κατάρρευση της αβεβαιότητας (καθιστώντας το δίκτυο "προβλέψιμο") και, συνεπώς, μια μετρήσιμη πτώση στην εντροπία, η οποία λειτουργεί ως το σήμα της εισβολής για το σύστημα.

1.2 Στόχοι της Εργασίας

Κύριος στόχος της παρούσας εργασίας αποτελεί η ανάδειξη της αποδοτικότητας μιας εναλλακτικής αρχιτεκτονικής ανίχνευσης εισβολών, η οποία διαφοροποιείται από τις καθιερωμένες μεθόδους του κατεστημένου. Δεδομένου ότι νέες κυβερνοεπιθέσεις αναπτύσσονται διαρκώς από κακόβουλους παράγοντες που εξελίσσουν αδιάκοπα τις τεχνικές τους, καθίσταται επιτακτική η ανάγκη για τους υπευθύνους ασφάλειας να αναζητούν καινοτόμες προσεγγίσεις, πέραν των παραδοσιακών εργαλείων, προκειμένου να προστατέψουν αποτελεσματικά τις υποδομές τους.

Παράλληλα, η έρευνα αυτή λειτουργεί ως το θεμελιώδες, στατικό μέρος ενός ευρύτερου ερευνητικού πλαισίου. Απώτερος σκοπός δεν είναι μόνο η θεωρητική σχεδίαση ενός συστήματος ανίχνευσης μέσω συμπεριφορικής ανάλυσης, αλλά η μελλοντική προσομοίωση ενός πλήρους δικτυακού περιβάλλοντος όπου το προτεινόμενο σχήμα θα μεταβεί από τη στατική offline ανάλυση σε πλήρη λειτουργία και αξιολόγηση σε πραγματικό χρόνο.

1.3 Δομή της Αναφοράς

Η συνέχεια της παρούσας αναφοράς είναι οργανωμένη ως εξής: Στο Κεφάλαιο 2 παρατίθεται το θεωρητικό υπόβαθρο, αναλύοντας τις έννοιες της εντροπίας Shannon και των Μαρκοβιανών αλυσίδων, καθώς και μια επισκόπηση των σύγχρονων προσεγγίσεων. Το Κεφάλαιο 3 εμβαθύνει στη μεθοδολογία που ακολουθήθηκε, με έμφαση στη μηχανική δεδομένων (Data Engineering) και τη διαδικασία εκπαίδευσης. Στο Κεφάλαιο 4 περιγράφεται η υλοποίηση της αρχιτεκτονικής Multi-Sensor Fusion. Το Κεφάλαιο 5 παρουσιάζει τα πειράματα και αξιολογεί τα αποτελέσματα των μοντέλων, ενώ στο Κεφάλαιο 6 ακολουθεί μια εκτενής συζήτηση επί των ευρημάτων και των περιορισμών του συστήματος. Τέλος, το Κεφάλαιο 7 συνοψίζει τα συμπεράσματα και προτείνει κατευθύνσεις για μελλοντική έρευνα.

2 Θεωρητικό Υπόβαθρο και Βιβλιογραφική Επισκόπηση

Το δεύτερο κεφάλαιο εισάγει τα θεμελιώδη μαθηματικά πάνω στα οποία δομήθηκε το σύστημα. Αποφεύγοντας την πολυπλοκότητα των μοντέλων Μηχανικής Μάθησης που στερούνται αιτιολόγησης, η ανάλυση μας βασίζεται σε ισχυρές θεωρητικές προσεγγίσεις από τη θεωρία των Πιθανοτήτων.

2.1 Θεωρία Διακριτών Πηγών και Εντροπία

Όπως περιγράφεται από τη θεωρία των διακριτών πηγών, κάθε σύστημα επικοινωνίας μπορεί να μοντελοποιηθεί ως μια πηγή που εκπέμπει σύμβολα από ένα πεπερασμένο αλφάβητο. Η μέτρηση της αβεβαιότητας που περιβάλλει το επόμενο σύμβολο γίνεται χρησιμοποιώντας τον τυπο της εντροπίας (Zervas, 2026). Η μαθηματική αυτή ποσότητα παριστάνει την **αβεβαιότητα της πληροφορίας** (Shannon, 1948). Δεδομένης μιας ακολουθίας γεγονότων, η εντροπία υπό συνθήκη (Conditional Entropy) ορίζεται ως:

$$H(Y|X) = - \sum_{x,y} p(x,y) \log_2 p(y|x) \quad (1)$$

Στο πλαίσιο του δικτύου μας, το X αντιπροσωπεύει την τρέχουσα συμπεριφορά του δικτύου, ενώ το Y αντιπροσωπεύει το αμέσως επόμενο βήμα. Η εξίσωση αυτή μετρά την αβεβαιότητα του επόμενου πακέτου δεδομένου του παρελθόντος. Όπως έχει παρατηρηθεί σε προγενέστερες έρευνες (Nychis et al., 2008), μια αυτοματοποιημένη δικτυακή επίθεση δημιουργεί μια υπερβολικά επαναλαμβανόμενη συμπεριφορά, καθώς ένα κακόβουλο λογισμικό εκτελεί τον ίδιο βρόχο λειτουργιών. Κατά συνέπεια, η αβεβαιότητα του επόμενου βήματος σχεδόν μηδενίζεται, κάτι που αντανακλάται σε δραματική πτώση της εντροπίας.

2.2 Μοντελοποίηση Στοχαστικών Διαδικασιών

Για τη χαρτογράφηση της ακολουθίας των πακέτων (που αποτελεί μια στοχαστική διαδικασία) επιλέχθηκε το μαθηματικό μοντέλο των Μαρκοβιανών Αλυσίδων, το οποίο εκπαιδεύεται μέσω ενός αυστηρά ντετερμινιστικού αλγορίθμου καταμέτρησης συχνοτήτων, προσφέροντας απόλυτη σταθερότητα και

επαναληψιμότητα στα αποτελέσματα. Το κρίσιμο ερώτημα κατά τον σχεδιασμό αφορούσε την επιλογή της τάξης (k) της αλυσίδας.

Η επιλογή τάξης $k = 1$ τεκμηριώνεται ρητά από τη βιβλιογραφία για συστήματα αποτροπής εισβολών (Ye *et al.*, 2002) καθώς και επιβεβαιώνεται στην πειραματική διαδικασία του έργου παρακάτω. Αν επιλέγαμε μεγαλύτερο k (π.χ. 3 ή 5), η αλυσίδα θα προσπαθούσε να απομνημονεύσει συνδυασμούς τριών ή πέντε διαδοχικών πακέτων. Παρόλο που αυτό θεωρητικά παρέχει μεγαλύτερη «μνήμη» στο σύστημα, πρακτικά το μέγεθος του πίνακα μεταβάσεων αυξάνεται εκθετικά, δημιουργώντας χιλιάδες άδειες καταστάσεις.

Αυτό το φαινόμενο του State-Space Explosion, έχει ως αποτέλεσμα η εντροπία εκπαίδευσης να καταρρέει (αφού οι περισσότερες μεταβάσεις έχουν πιθανότητα 1 ή 0). Το σύστημα περνάει από τη φάση της «εκμάθησης» στη φάση της «απομνημόνευσης» (Overfitting). Κατά την αξιολόγηση σε πραγματικά δεδομένα, οποιαδήποτε φυσιολογική αλλά άγνωστη παραλλαγή της κίνησης ερμηνεύεται λανθασμένα ως επίθεση, οδηγώντας σε δραματική αύξηση στα False Positives. Συνεπώς, η Μαρκοβιανή Αλυσίδα 1ης τάξης αποτελεί τη χρυσή τομή μεταξύ απόδοσης και ικανότητας γενίκευσης.

2.3 Επισκόπηση της Βιβλιογραφίας και Διαφορετικές Προσεγγίσεις

Σε επίπεδο σύγκρισης στοχαστικών μοντέλων, οι Ye *et al.* (2002) μελέτησαν τη διαφορά μεταξύ Μαρκοβιανών αλυσίδων πρώτης τάξης και στοχαστικών μοντέλων ανώτερης τάξης για την ανάλυση ακολουθιών από γεγονότα (audit data). Η έρευνά τους απέδειξε ότι ένα μοντέλο πρώτης τάξης αποτελεί την ιδανική τομή μεταξύ υπολογιστικής ταχύτητας και ακρίβειας, υπερτερώντας σε απόδοση (σε συνθήκες πραγματικού χρόνου) έναντι των πιο περίπλοκων μοντέλων (Ye *et al.*, 2002). Εξελίσσοντας την ίδια σκέψη, οι Ye, Zhang και Borror (2004) αξιολόγησαν την ανθεκτικότητα αυτών των Μαρκοβιανών μοντέλων, αποδεικνύοντας ότι αν και λειτουργούν άψογα σε “καθαρά” δεδομένα, η ακρίβειά τους φθίνει ραγδαία όσο αυξάνεται ο θόρυβος στο δίκτυο, αναδεικνύοντας την ανάγκη για προσεκτική προεπεξεργασία της κίνησης (Ye *et al.*, 2004).

Στον τομέα της Θεωρίας Πληροφορίας, οι Lee και Xiang (2001) εισήγαγαν προηγμένες μετρικές (όπως η Εντροπία υπό Συνθήκη και το Κέρδος Πληροφορίας) για την αυτοματοποίηση της δημιουργίας μοντέλων. Η μέθοδός τους εξαλείφει την ανάγκη για δοκιμές βασισμένες στο trial-and-error, υπολογίζοντας μαθηματικά το βέλτιστο μέγεθος του χρονικού παραθύρου παρατήρησης της κίνησης (Lee and Xiang, 2001). Παράλληλα, οι Nychis *et al.* (2008) αξιολόγησαν εμπειρικά την ανίχνευση βάσει εντροπίας, καταλήγοντας στο ότι οι κατανομές των διευθύνσεων IP και των θυρών είναι περιττές αν όχι και υπερβολικά συσχετισμένες, καθώς και ότι τα σύγχρονα συστήματα πρέπει να εξετάζουν συμπεριφορικά χαρακτηριστικά (όπως ο βαθμός διασποράς In/Out-degree) προκειμένου να εντοπίζουν σύνθετες επιθέσεις σάρωσης και δικτύων P2P (Nychis *et al.*, 2008).

Μια διαφορετική προσέγγιση υπήρξε η χρήση αλγορίθμων συμπίεσης για τον εντοπισμό ανωμαλιών. Οι Callegari *et al.* (2009) εφάρμοσαν αλγόριθμους συμπίεσης (Huffman, LZW, Dynamic Markov Coding) στηριζόμενοι στη λογική ότι η εντροπία καθορίζει το όριο της συμπίεσης. Έτσι, μια κίνηση θεωρείται ανώμαλη εάν αποκλίνει από το αναμενόμενο “λεξικό” συμπίεσης του φυσιολογικού TCP traffic (Callegari *et al.*, 2009). Πιο πρόσφατα, οι Ting *et al.* (2018) εξέλιξαν δραματικά αυτήν την ιδέα εισάγοντας τη μέθοδο “Slice Compression” (SCADe) μέσω NCD (Normalized Compression Distance). Το σύστημά τους μπορεί να

αναγνωρίζει τοπικές ανωμαλίες χωρίς καμία εκ των προτέρων γνώση για τα χαρακτηριστικά των πρωτοκόλλων (Ting et al., 2018).

Τέλος, όπως συνοψίζεται και στην εκτενή βιβλιογραφική ανασκόπηση των Ahmed, Mahmood και Hu (2016), η επιστημονική κοινότητα έχει πλέον διαχωρίσει τις τεχνικές σε στατιστικές, ταξινομικές (classification) και ομαδοποίησης (clustering), καταδεικνύοντας ξεκάθαρα τη στροφή προς τις μη-επιβλεπόμενες (unsupervised) προσεγγίσεις για την αντιμετώπιση επιθέσεων Zero-day (Ahmed et al., 2016).

2.4 Συμπεράσματα και Κατεστημένο (State of the Art)

Συνοψίζοντας τη βιβλιογραφία, το σημερινό «κατεστημένο» στην ανίχνευση εισβολών έχει απομακρυνθεί κατά πολύ από τα παραδοσιακά firewalls και τα συστήματα που βασίζονται σε υπογραφές (signature-based DPI). Η αιχμή της τεχνολογίας εστιάζει στην ανάλυση συμπεριφοράς χωρίς επίβλεψη (unsupervised behavioral analysis), αξιοποιώντας έννοιες από τη Θεωρία Πληροφορίας και τη Μοντελοποίηση Στοχαστικών Διαδικασιών πάνω στα μεταδεδομένα της κίνησης. Ωστόσο, ο κοινός παρονομαστής όλων των ερευνών είναι ότι κανένα μεμονωμένο στατιστικό χαρακτηριστικό ή μοναδικός αισθητήρας δεν επαρκεί. Η κίνηση είναι υπερβολικά θορυβώδης, οδηγώντας εύκολα σε Ψευδώς Θετικά ή Ψευδώς Αρνητικά αποτελέσματα. Συνεπώς, η εξέλιξη της βιομηχανίας επιτάσσει τη χρήση της Multi-Sensor Fusion αρχιτεκτονικής, η οποία συνθέτει πολλαπλά χαρακτηριστικά (όγκους, συχνότητες, ταχύτητες) και διασταυρώνει τα αποτελέσματα για να δημιουργήσει την πλέον ανθεκτική και αξιόπιστη ασπίδα απέναντι σε άγνωστες απειλές.

2.5 Συγκριτική Ανάλυση Μεθόδων

Λαμβάνοντας υπόψη τη σύγχρονη βιβλιογραφία, η παρούσα εργασία υιοθετεί μια υβριδική προσέγγιση. Ενώ η αρχιτεκτονική μας θεμελιώνεται πάνω σε δοκιμασμένες state-of-the-art πρακτικές, όπως η χρήση Εντροπίας Shannon και στοχαστικών μοντέλων 1ης τάξης για την αποφυγή της υπερεκπαίδευσης, ταυτόχρονα διαφοροποιείται εισάγοντας καινοτόμα χαρακτηριστικά μηχανικής δεδομένων. Χαρακτηριστικό παράδειγμα αποτελεί η αντιμετώπιση των διακριτών σημάτων ελέγχου (TCP Flags), τα οποία αντί να αντιμετωπίζονται ως μεμονωμένα κείμενα ή ανεξάρτητες μεταβλητές, ομαδοποιούνται αλγοριθμικά μέσω δυαδικής συμπίεσης (bitmasking) σε έναν ενιαίο ακέραιο αριθμό, δημιουργώντας 64 μοναδικές καταστάσεις (βλ. Απόσπασμα Κώδικα 1 στο Παράρτημα Α). Σε συνδυασμό με την αρχιτεκτονική Multi-Sensor Fusion που καλύπτει τα "τυφλά σημεία" των μεμονωμένων αισθητήρων, και τη χρήση εξειδικευμένων μαθηματικών μετασχηματισμών όπως η λογαριθμική κλίμακα:

$$\log_{1p}(x) = \log(1 + x) \quad (2)$$

για την αποφυγή υπολογιστικών καταρρεύσεων (βλ. Απόσπασμα Κώδικα 2 στο Παράρτημα Α), το προτεινόμενο σύστημα επεκτείνει τις δυνατότητες του υφιστάμενου κατεστημένου. Όλες αυτές οι αρχιτεκτονικές επιλογές αναλύονται εκτενώς στα επόμενα κεφάλαια της μεθοδολογίας.

2.6 Αξιολόγηση Αποκλίσεων (Cross-Entropy)

Κατά τη φάση ανίχνευσης, το σύστημα παρακολουθεί την τρέχουσα κίνηση και υπολογίζει την απόκλιση από το μοντέλο εκπαίδευσης μέσω του Cross-Entropy

Loss (Zervas, 2025). Η λειτουργία βασίζεται στην αναγωγή των πιθανοτήτων σε τιμές πληροφορίας.

Ωστόσο, δημιουργείται ένα σοβαρό μαθηματικό ζήτημα όταν το σύστημα συναντήσει μια μετάβαση κατά τη διάρκεια του ελέγχου, η οποία δεν υπήρχε απολύτως πουθενά στο σύνολο εκπαίδευσης (δηλαδή $p = 0$). Επειδή ο λογάριθμος του μηδενός δεν ορίζεται και τείνει στο μείον άπειρο, χρησιμοποιείται η τεχνική της εξομάλυνσης Laplace smoothing (Ye et al., 2004) (βλ. Απόσπασμα Κώδικα 4 στο Παράρτημα Α). Σε κάθε άγνωστη μετάβαση, αναθέτουμε μια εξαιρετικά μικρή πιθανότητα της τάξης του 1.0×10^{-9} . Ο αρνητικός λογάριθμος με βάση το 2 για το 10^{-9} ισούται περίπου με 29.9 bits. Αυτό το νούμερο εκτοξεύει την αποκλιση σε εξωφρενικά επίπεδα, παρέχοντας ένα αδιαμφισβήτητο σήμα συναγερμού για την ύπαρξη εξαιρετικά ανώμαλης συμπεριφοράς.

3 Μεθοδολογία

Η αρχιτεκτονική του συστήματος χωρίζεται σε τρεις διακριτές φάσεις: την επεξεργασία δεδομένων, την εκπαίδευση του στατιστικού μοντέλου (Training), και την παραγωγή του συστήματος ανίχνευσης (Detection).

Η εκπαίδευση βασίζεται στη φιλοσοφία του Unsupervised Anomaly Detection. Εκπαιδεύουμε το σύστημα αποκλειστικά σε απολύτως υγιή κίνηση, αφήνοντας το να μάθει τον «φυσιολογικό παλμό» του δικτύου χωρίς απολύτως καμία γνώση για τους τύπους των επιθέσεων που θα κληθεί να αντιμετωπίσει.

3.1 Περιγραφή Συνόλου Δεδομένων

Για την αξιολόγηση και εκπαίδευση του συστήματος, επιλέχθηκε ένα σύγχρονο και εξαιρετικά εκτενές σύνολο δεδομένων δικτυακής κίνησης, ικανό να προσομοιώσει ρεαλιστικές συνθήκες φόρτου και επιθέσεων. Μια καλή πρακτική της παρούσας μεθοδολογίας αφορά τον τρόπο διαχείρισης και ενσωμάτωσης αυτού του συνόλου δεδομένων στο σύστημα ανίχνευσης. Σε αντίθεση με τις συμβατικές ακαδημαϊκές προσεγγίσεις που βασίζονται στην τοπική λήψη και αποθήκευση στατικών αρχείων στον σκληρό δίσκο, το προτεινόμενο Data Pipeline σχεδιάστηκε ώστε να αντλεί τον όγκο των δεδομένων δυναμικά και απευθείας από το AWS Open Data Registry. Αυτή η επιλογή καθιστά το σύστημα πλήρως αυτόνομο και άμεσα αναπαραγώγιμο από οποιονδήποτε τρίτο ερευνητή, εξαλείφοντας τους περιορισμούς του τοπικού αποθηκευτικού χώρου. Παράλληλα, καθιστά την αρχιτεκτονική εξ ορισμού έτοιμη (Cloud-native) για άμεση ανάπτυξη και κλιμάκωση σε υποδομές υπολογιστικού νέφους, όπου η ροή δικτυακών δεδομένων είναι συνεχής.

Ωστόσο, η αξιοποίηση ακατέργαστων δικτυακών δεδομένων τέτοιας κλίμακας απαιτεί ένα εξαιρετικά αυστηρό στάδιο προεπεξεργασίας προτού τα δεδομένα τροφοδοτηθούν στους αισθητήρες της Μαρκοβιανής αλυσίδας. Για τον λόγο αυτό, δημιουργήθηκε μια ισχυρή αλυσίδα επεξεργασίας (το γνωστό Data Pipeline), η πρώτη φάση της οποίας ήταν αφιερωμένη στον **“επιθετικό” καθαρισμό** και φιλτράρισμα. Αρχικά, πραγματοποιήθηκε σάρωση των διαστάσεων των αρχείων, από την οποία εντοπίστηκαν και αφαιρέθηκαν εξ ολοκλήρου πολυάριθμες **“νεκρές” στήλες** που δεν περιείχαν απολύτως καμία πληροφορία ή ήταν γεμάτες με ακαθόριστες τιμές (NaN/Null), μειώνοντας άσκοπα την υπολογιστική ταχύτητα. Επιπρόσθετα, εφαρμόστηκαν αυστηροί κανόνες απαλοιφής γραμμών (row dropping): πακέτα με ελλιπή χαρακτηριστικά ροής (missing values), καταστραμμένες

εγγραφές, ή διπλοτυπίες που προέκυψαν από σφάλματα των εργαλείων καταγραφής, διαγράφηκαν. Το αποτέλεσμα αυτού του εντατικού φιλτραρίσματος ήταν η παραγωγή ενός συμπαγούς, "καθαρισμένου" και αξιόπιστου συνόλου παρατηρήσεων, το οποίο αποτελεί το ιδανικό υπόστρωμα για την αμερόληπτη εκπαίδευση των αλγορίθμων Θεωρίας Πληροφορίας, εγγυώμενο ότι οι όποιες αποκλίσεις εντοπιστούν αργότερα θα οφείλονται ξεκάθαρα σε ανωμαλίες συμπεριφοράς και όχι σε θόρυβο των δεδομένων.

3.2 Επιλογή Χαρακτηριστικών και Μηχανική Δεδομένων

Από το πλήθος των διαθέσιμων χαρακτηριστικών του NetFlow, επιλέχθηκαν πέντε βασικά, εμπνευσμένα από μελέτες αξιολόγησης στην ασφάλεια πληροφοριών (Lee and Xiang, 2001):

- **Χρονική Διάρκεια (Flow_Duration):** Κρίσιμης σημασίας για την ανίχνευση αργών επιθέσεων (π.χ. Slowloris) που προσπαθούν να κρατήσουν ανοιχτές συνδέσεις για τεράστια χρονικά διαστήματα.
- **Βαθμός Διασποράς (Out_Degree):** Αντιπροσωπεύει τον αριθμό των διαφορετικών προορισμών (διασπρά) με τους οποίους επικοινωνεί ένας υπολογιστής. Οι αλλαγές σε αυτό αποτελούν τη βασικότερη ένδειξη για επιθέσεις Port Scanning.
- **Συνολικός Αριθμός Πακέτων (Tot_Fwd_Pkts):** Αντανακλά την ύπαρξη επιθέσεων Brute-Force όπου τεράστιος αριθμός αιτημάτων αποστέλλεται σε μικρό χρονικό διάστημα.
- **Συνολικός Όγκος Πακέτων (TotLen_Fwd_Pkts):** Αποτελεί τον βασικό δείκτη ανίχνευσης προσπαθειών μαζικής εξαγωγής ή κλοπής δεδομένων (Data Exfiltration).
- **Σημάνσεις Ελέγχου 'TCP_Flags_Int':** Οι έξι ήδη διακριτές σημάνσεις ελέγχου (SYN, ACK, FIN, RST, PSH, URG) συμπύχθηκαν στο δυαδικό σύστημα (bitmasking) και έτσι, η σημάνση δεν είναι απλά κείμενο, αλλά παράγει ακριβώς έναν ακέραιο αριθμό από το 0 έως το 63. Δημιουργούνται δηλαδή ακριβώς **64 μοναδικές και μη επικαλυπτόμενες καταστάσεις** ενσωματώνοντας ιδανικά τα διαφορετικά flags σε μία και μόνο μαθηματική μεταβλητή (βλ. Απόσπασμα Κώδικα 1 στο Παράρτημα Α).

Για τη γρήγορη επεξεργασία αυτών των αρχείων, τα οποία ξεπερνούσαν τα αρκετά Gigabytes, αντικαταστήσαμε τα παραδοσιακά εργαλεία ενιαίου νήματος με τη βιβλιοθήκη Polars, η οποία γράφτηκε σε Rust και προσφέρει πολυνηματική αρχιτεκτονική και διανυσματική εκτέλεση εντολών.

3.3 Διακριτοποίηση και Εξομάλυνση

Τα μαθηματικά της εντροπίας απαιτούν διακριτές καταστάσεις. Ωστόσο, τα δεδομένα του δικτύου (όπως ο χρόνος ή το μέγεθος) είναι συνεχή (εκτός από τις σημάνσεις ελέγχου για τις οποίες αναφερθήκαμε μόλις παραπάνω) οπότε έπρεπε να γίνει διακριτοποίηση αυτών των υπόλοιπων μεταβλητών.

Χρησιμοποιήθηκε η μέθοδος του Equal-Width Binning, η οποία διαχώρισε κάθε συνεχή μεταβλητή σε ακριβώς 8 κατηγορίες. Το πρόβλημα με τα ακραία νούμερα του δικτύου είναι ότι δημιουργούν τεράστιες, κενές περιοχές. Για να προστατέψουμε την κατανομή, όλα τα νούμερα μετατράπηκαν σε λογαριθμική

κλίμακα πριν την κατηγοριοποίηση. Ειδικότερα, για την αποφυγή μαθηματικών σφαλμάτων όταν ένα χαρακτηριστικό (όπως το 'Out_Degree') πάρει την τιμή μηδέν (όπου το $\log(0)$ δεν ορίζεται), χρησιμοποιήσαμε τη συνάρτηση $\log(1+x)$ ή $\log 1p(x)$, η οποία διασφαλίζει ότι $\log 1p(0) = 0$ (βλ. Απόσπασμα Κώδικα 2 στο Παράρτημα Α).

3.4 Αρχιτεκτονική Μοντέλου και Διαδικασία "Εκπαίδευσης"

Η καρδιά του συστήματος ανίχνευσης αναπτύχθηκε σε γλώσσα Python, αξιοποιώντας εξειδικευμένες βιβλιοθήκες ανάλυσης δεδομένων για την ταχύτατη επεξεργασία των διακριτοποιημένων ροών. Η αρχιτεκτονική εκπαίδευσης σχεδιάστηκε με γνώμονα την ανεξαρτησία των χαρακτηριστικών: το μοντέλο δεν αντιμετωπίζει την κίνηση ως ένα ενιαίο, αδιαχώριστο σύνολο, αλλά εκπαιδεύεται αυτόνομα για κάθε μεμονωμένο χαρακτηριστικό του δικτύου (Flow Duration, TCP Flags, κ.ά.).

Κατά τη διαδικασία "εκπαίδευσης", ο αλγόριθμος σαρώνει τις παρατηρήσεις της απολύτως φυσιολογικής κίνησης (Training Set). Για κάθε ανεξάρτητο χαρακτηριστικό, χαρτογραφεί την αλληλουχία των καταστάσεων και δημιουργεί έναν αποκλειστικό Πίνακα Πιθανοτήτων Μετάβασης (Transition Probability Matrix). Αυτός ο πίνακας αποτυπώνει μαθηματικά την πιθανότητα το σύστημα να μεταβεί από την τρέχουσα κατάσταση στην αμέσως επόμενη, εδραιώνοντας έτσι τον κανόνα της Μαρκοβιανής Αλυσίδας 1ης τάξης (βλ. Απόσπασμα Κώδικα 3 στο Παράρτημα Α). Βάσει αυτού του πίνακα, υπολογίζεται στη συνέχεια η βασική Εντροπία Shannon (Baseline Entropy) του χαρακτηριστικού, η οποία λειτουργεί ως το ψηφιακό αποτύπωμα της "υγιούς" αβεβαιότητας του δικτύου.

Αν και η βιβλιογραφία προτείνει τη χρήση 1ης τάξης, στη μεθοδολογία χρησιμοποιήθηκε μια αυστηρά πειραματική προσέγγιση για την επαλήθευση αυτής της θεωρίας. Ο αλγόριθμος εκπαίδευσης παραμετροποιήθηκε και εκτελέστηκε πολλαπλές φορές, προκειμένου να κατασκευάσει πίνακες μεταβάσεων όχι μόνο για $k=1$, αλλά και για μεγαλύτερες Μαρκοβιανές τάξεις (όπως $k=2$, $k=3$, και $k=5$). Στόχος αυτής της πειραματικής επέκτασης ήταν να διαπιστωθεί εάν η "βαθύτερη μνήμη" του παρελθόντος βελτιώνει την ικανότητα γενίκευσης του συστήματος ή εάν το οδηγεί σε μαθηματική κατάρρευση. Πράγματι για τάξη $k=1$ τα αποτελέσματα είναι βέλτιστα. Η ενδελεχής ανάλυση αυτών των baseline πειραμάτων παρατίθεται στο Κεφάλαιο 5.

Η αρχιτεκτονική ολοκληρώνεται στη φάση της αξιολόγησης (Detection / Inference). Έχοντας πλέον "μάθει" την κατανομή της υγιούς κίνησης, το σύστημα δέχεται νέα, άγνωστα δεδομένα. Αντί να υπολογίσει ξανά την εντροπία τους από το μηδέν, χρησιμοποιεί τη συνάρτηση της Σταυροειδούς Εντροπίας (Cross-Entropy). Συγκρίνει δηλαδή την παρατηρούμενη αλληλουχία των νέων δεδομένων με τις πιθανότητες που έχει αποθηκεύσει στον πίνακα μεταβάσεων της εκπαίδευσης. Μέσω αυτού του υπολογισμού, το σύστημα εξάγει μια τιμή απόκλισης (Loss): όσο μεγαλύτερη είναι η τιμή της σταυροειδούς εντροπίας, τόσο πιο σίγουρο είναι το σύστημα ότι η παρατηρούμενη κίνηση δεν ανήκει στο φυσιολογικό προφίλ του δικτύου, σημαίνοντας έτσι συναγερμό για πιθανή κυβερνοεπίθεση.

4 Υλοποίηση

4.1 Περιβάλλον Ανάπτυξης

Για την υλοποίηση του συστήματος και την εκτέλεση των πειραμάτων, επιλέχθηκε το περιβάλλον Google Colaboratory (Colab), με διασύνδεση στο Google Drive (google.colab.drive).

Η συγκεκριμένη επιλογή υπαγορεύτηκε από τον τεράστιο όγκο των δικτυακών δεδομένων, η επεξεργασία των οποίων απαιτούσε δυναμική κατανομή πόρων και διαθέσιμη μνήμη (RAM) που συχνά υπερβαίνει τις δυνατότητες ενός συμβατικού υπολογιστή.

Μέσω του Colab, εξασφαλίστηκε η ορθή εκτέλεση του κώδικα, ο οποίος αναπτύχθηκε εξ ολοκλήρου σε Python 3.

Όσον αφορά το λογισμικό, δόθηκε ιδιαίτερη έμφαση στη βελτιστοποίηση της μηχανικής δεδομένων και για τον λόγο αυτό, εγκαταλείφθηκε η παραδοσιακή βιβλιοθήκη Pandas, και ενσωματώθηκε η βιβλιοθήκη Polars, η οποία, όπως αναφέρθηκε και παραπάνω είναι ιδανική για γρήγορη επεξεργασία μεγάλων πακέτων δεδομένων λόγω της πολυνηματικής λειτουργίας της, μειώνοντας έτσι δραματικά τους χρόνους φιλτραρίσματος των datasets.

Αξίζει να σημειωθεί ότι ο αλγόριθμος εκπαίδευσης της Μαρκοβιανής Αλυσίδας δεν βασίστηκε σε κάποια έτοιμη βιβλιοθήκη μηχανικής μάθησης, αλλά αναπτύχθηκε από το μηδέν.

Για την καταμέτρηση των καταστάσεων και των μεταβάσεων της αλυσίδας αξιοποιήθηκαν ενσωματωμένες δομές της Python (`collections.defaultdict`), ενώ για την κατασκευή των πινάκων μεταβάσεων, τους υπολογισμούς πιθανοτήτων και την **εξαγωγή της Εντροπίας**, χρησιμοποιήθηκε εκτενώς η βιβλιοθήκη NumPy, η οποία εγγυάται γρήγορους διανυσματικούς υπολογισμούς.

Επιπλέον, για τη διαχείριση της διαμόρφωσης του συστήματος και την αποθήκευση του εκπαιδευμένου μοντέλου χρησιμοποιήθηκαν οι βιβλιοθήκες `yaml` και `json`.

Τέλος, στο στάδιο της αξιολόγησης και οπτικοποίησης των αποτελεσμάτων, επιστρατεύτηκαν οι βιβλιοθήκες Plotly για την παραγωγή διαδραστικών γραφημάτων ανίχνευσης, καθώς και οι Matplotlib και Scikit-Learn για τον υπολογισμό των μετρικών αξιολόγησης (Precision, Recall, F1-Score, ROC-AUC) και την αποτύπωση των πινάκων σύγχυσης (Confusion Matrices).

4.2 Αρχιτεκτονική Πολλαπλών Αισθητήρων

Το πρόβλημα με πολλά συστήματα ανίχνευσης ανωμαλιών είναι ότι βασίζονται σε μία μόνο μετρική (έναν αισθητήρα) για να βγάλουν συμπεράσματα. Όπως έχει αποδειχθεί στη βιβλιογραφία, η χρήση μόνο ενός αισθητήρα οδηγεί αναπόφευκτα σε False Negatives (*Nychis et al., 2008*).

Για παράδειγμα, μια έξυπνη, κατανεμημένη επίθεση DDoS μπορεί να χρησιμοποιήσει εκατοντάδες διαφορετικές διευθύνσεις IP, με αποτέλεσμα το χαρακτηριστικό 'Out_Degree' να μοιάζει απολύτως φυσιολογικό. Αν το σύστημα κοιτούσε μόνο αυτό, η επίθεση θα περνούσε απαρατήρητη.

Για τον λόγο αυτό, αναπτύχθηκε η αρχιτεκτονική συγχώνευσης πολλαπλών αισθητήρων (το γνωστό πλέον Multi-Sensor Fusion). Η ταυτόχρονη χρήση και των πέντε χαρακτηριστικών ως ανεξάρτητων παρατηρητών εξαλείφει αυτό το πρόβλημα. Το σύστημα αναλύει τις Μαρκοβιανές αλυσίδες όλων των χαρακτηριστικών ταυτόχρονα, και λειτουργεί ως λογική πύλη OR (βλ. Απόσπασμα Κώδικα 5 στο Παράρτημα Α). Αν η κανονικοποιημένη απόκλιση έστω και ενός

αισθητήρα ξεπεράσει το καθολικό όριο (> 1.0), τότε κηρύσσεται συναγερμός, παρέχοντας ολοκληρωμένη κάλυψη σε όλες τις επιφάνειες επίθεσης.

5 Πειράματα και Αποτελέσματα

Η πειραματική μας ανάλυση επιβεβαιώνει τη θεωρία που παρουσιάστηκε. Εξετάζοντας τα αποτελέσματα κατά τη διάρκεια της δοκιμής των μοντέλων, αποδείξαμε την αναγκαιότητα χρήσης τάξης $k = 1$.

5.1 Baseline Αποτελέσματα

Στον Πίνακα 1 παρουσιάζεται ο αριθμός των μοναδικών καταστάσεων που εντόπισε το σύστημα σε ένα δείγμα εκατοντάδων χιλιάδων πακέτων, και πώς καταρρέει η εντροπία της βάσης όταν αυξάνεται η τάξη.

Πίνακας 1: Αριθμός Μοναδικών Καταστάσεων και Εντροπία Βάσης Ανάλογα με την Τάξη k του Μοντέλου (Μέγεθος Ακολουθίας: 488,381)

Χαρακτηριστικό	$k = 1$		$k = 2$		$k = 3$		$k = 5$	
	Καταστάσεις	H	Καταστ.	H	Καταστ.	H	Καταστ.	H
TCP_Flags_Int_sym	11	2.035	97	1.872	656	1.639	13657	1.119
Flow_Duration_sym	7	2.534	49	2.533	343	2.514	15090	1.832
TotLen_Fwd_Pkts_sym	8	1.444	-	-	-	-	2076	1.318
Out_Degree_sym	1	0.000	-	-	-	-	1	0.000

Ο παραπάνω πίνακας αποτυπώνει με απόλυτη μαθηματική σαφήνεια τον αντίκτυπο που έχει η αύξηση της τάξης k της Μαρκοβιανής Αλυσίδας στην πολυπλοκότητα και τη γενικευτική ικανότητα του μοντέλου.

Αναλύοντας τη συμπεριφορά των επιμέρους χαρακτηριστικών, προκύπτουν τρία βασικά συμπεράσματα που δικαιολογούν την τελική αρχιτεκτονική επιλογή του $k=1$.

Πρώτον, παρατηρείται το φαινόμενο της **Εκθετικής Έκρηξης Χώρου Καταστάσεων**. Στα χαρακτηριστικά υψηλής μεταβλητότητας, όπως τα TCP Flags και το Flow Duration, η 1η τάξη ($k=1$) παράγει έναν συμπαγή και φυσιολογικό αριθμό καταστάσεων (11 και 7 αντίστοιχα), ο οποίος είναι απολύτως επαρκής για να χαρτογραφήσει τους θεμελιώδεις κανόνες επικοινωνίας (π.χ. τους κανόνες συμφωνίας του TCP Handshake).

Αντιθέτως, αναγκάζοντας το σύστημα να απομνημονεύσει αλληλουχίες πέντε διαδοχικών πακέτων ($k=5$), οι πιθανές καταστάσεις εκτοξεύονται στις 13.657 και 15.090.

Αυτή η δραματική αύξηση αποδεικνύει ότι το μοντέλο περνάει από τη φάση της εκμάθησης κανόνων στη φάση της **στείρας απομνημόνευσης**.

Η ταυτόχρονη πτώση της Εντροπίας (π.χ. στα TCP Flags από 2.035 σε 1.119) επιβεβαιώνει ότι ο πίνακας μεταβάσεων γεμίζει με απόλυτες πιθανότητες της τάξης του 100% ή 0%, καθιστώντας το μοντέλο ανίκανο να αναγνωρίσει οποιαδήποτε φυσιολογική -αλλά ελαφρώς παραλλαγμένη- μελλοντική κίνηση, κάτι που θα οδηγούσε σε ραγδαία αύξηση Ψευδώς Θετικών συναγερμών.

Δεύτερον, η συμπεριφορά του χαρακτηριστικού Out Degree επιβεβαιώνει τη σταθερότητα της τοπολογίας του δικτύου κατά τη διάρκεια της κανονικής λειτουργίας.

Το γεγονός ότι το χαρακτηριστικό αυτό παρουσιάζει μόλις 1 κατάσταση με μηδενική εντροπία ($H=0.000$) στην 1η τάξη, σημαίνει ότι η δικτυακή διασπορά είναι απολύτως σταθερή και ντετερμινιστική.

Συνεπώς, είναι μαθηματικά αδύνατο η αύξηση της τάξης να παραγάγει νέα πληροφορία (καθώς μια ακολουθία από 5 ολόιδιες τιμές παραμένει μία μοναδική κατάσταση).


Αυτό εξηγεί γιατί το Out Degree διατηρεί 1 κατάσταση και μηδενική εντροπία ακόμα και στο $k=5$.

Τρίτον, για μεταβλητές όπως το Total Length of Forward Packets, η τάση της εκθετικής αύξησης (από 8 καταστάσεις στο $k=1$, στις 2.076 στο $k=5$) είναι τόσο ραγδαία και ξεκάθαρη, που η υπολογιστική εξαγωγή των ενδιάμεσων τάξεων ($k=2,3$) κρίθηκε ανούσια και παραλείφθηκε (όπως υποδηλώνουν οι παύλες στον πίνακα).

Εν κατακλείδι, η Μαρκοβιανή Αλυσίδα 1ης τάξης αποδεικνύεται η "χρυσή τομή", καθώς κατορθώνει να διατηρεί την αβεβαιότητα του συστήματος σε επίπεδα που επιτρέπουν την υγιή μεταβλητότητα της κίνησης, διατηρώντας ταυτόχρονα το υπολογιστικό κόστος σε ελάχιστα επίπεδα.

5.2 Γραφική Αξιολόγηση

Πτώση Εντροπίας Ανάλογα με την Τάξη k



Σχήμα 1: Πτώση της εντροπίας καθώς αυξάνεται η τάξη του μοντέλου (k)

Το παραπάνω σχήμα επιβεβαιώνει οπτικά τον θεμελιώδη κανόνα της Θεωρίας Πληροφορίας: καθώς αυξάνεται η ποσότητα της διαθέσιμης πληροφορίας από το παρελθόν (δηλαδή η τάξη k), η αβεβαιότητα για την επόμενη κατάσταση —και συνεπώς η Εντροπία υπό Συνθήκη (Conditional Entropy)— μειώνεται.

Ωστόσο, η συμπεριφορά αυτής της πτώσης διαφέρει ριζικά ανάλογα με τη φύση του εκάστοτε χαρακτηριστικού.

Για παράδειγμα, η εντροπία των TCP Flags (μπλε γραμμή) παρουσιάζει μια σταθερή και σχεδόν γραμμική πτώση, υποδεικνύοντας ότι το σύστημα "αποστηθίζει" προοδευτικά τις ακολουθίες ελέγχου του πρωτοκόλλου.


Από την άλλη, το Flow Duration (πράσινη γραμμή) επιδεικνύει μια ισχυρή ανθεκτικότητα μέχρι και την τάξη $k=3$, διατηρώντας την εντροπία του υψηλά, προτού καταρρεύσει απότομα στο $k=5$, σημείο στο οποίο ο χώρος καταστάσεων γίνεται πλέον υπερβολικά αραιός.

Ενδιαφέρον παρουσιάζει η συμπεριφορά του συνολικού μήκους πακέτων (κόκκινη γραμμή), η οποία εμφανίζει μια ελαφριά διακύμανση (πτώση στο $k=2$, άνοδο στο $k=3$) πριν την τελική της πτώση.

Αυτή η μη μονοτονική συμπεριφορά μαρτυρά τεχνητές ανωμαλίες που δημιουργούνται όταν ένας περιορισμένος αριθμός παρατηρήσεων κατανέμεται βίαια σε εκθετικά αυξανόμενες διαθέσιμες καταστάσεις.

Αντίθετα, χαρακτηριστικά με εγγενώς χαμηλή διακύμανση, όπως το σύνολο των προωθημένων πακέτων (πορτοκαλί γραμμή), ξεκινούν από ήδη χαμηλά επίπεδα εντροπίας, αποδεικνύοντας ότι είναι εξαιρετικά ντετερμινιστικά από τη φύση τους, καθιστώντας τις μεγαλύτερες τάξεις πρακτικά περιττές.

Ανάλυση Συμπεριφοράς Πολλαπλών Αισθητήρων



Σχήμα 2: Κανονικοποιημένη Απόκλιση πολλαπλών αισθητήρων κατά τη διάρκεια επιθέσεων

Το παραπάνω σχήμα αποτελεί την κορύφωση της πειραματικής αξιολόγησης του συστήματος, καθώς οπτικοποιεί ξεκάθαρα την υπεροχή της αρχιτεκτονικής Πολλαπλών Αισθητήρων σε συνθήκες πραγματικής επίθεσης. Στον οριζόντιο άξονα αποτυπώνεται η χρονική αλληλουχία της δικτυακής κίνησης (Flow Sequence Index), ενώ στον κάθετο άξονα μετράται η Κανονικοποιημένη Απόκλιση (Normalized Deviation) από το φυσιολογικό Μαρκοβιανό προφίλ.

Η διακεκομμένη μαύρη γραμμή ορίζει το καθολικό κατώφλι ανοχής (Threshold=1.0), πάνω από το οποίο το σύστημα σημαίνει συναγερμό.

Παράλληλα, η κόκκινη ένδειξη χαμηλά στο γράφημα υποδεικνύει την πραγματική χρονική διάρκεια των επιθέσεων (Ground Truth).

Η πιο κρίσιμη παρατήρηση αφορά τη διαφοροποιημένη αντίδραση των αισθητήρων κατά την έναρξη της επίθεσης.


Όπως διακρίνεται, ορισμένα χαρακτηριστικά (όπως η μπλε και η μωβ γραμμή) παραμένουν "ήρεμα" κάτω από το κατώφλι συναγερμού ακόμα και κατά τη διάρκεια της επίθεσης.

Εάν το σύστημα ανίχνευσης βασιζόταν αποκλειστικά σε αυτούς τους μεμονωμένους αισθητήρες, θα αποτύγχανε παταγωδώς, καταγράφοντας ένα κρίσιμο ΨΔ αποτέλεσμα.

Ωστόσο, χάρη στην ταυτόχρονη παρακολούθηση πολλαπλών διαστάσεων, ο αισθητήρας που παρακολουθεί τα προωθημένα πακέτα (πράσινη γραμμή) αντιδρά βίαια, με την απόκλισή του να εκτοξεύεται σε τιμές άνω του 6.0, διαπερνώντας emphatically το κατώφλι του 1.0 ακριβώς τη στιγμή που ξεκινά η κόκκινη ένδειξη της επίθεσης.

Η λειτουργία των αισθητήρων ως "**Λογική Πύλη OR**" (βλ. Απόσπασμα Κώδικα 5 στο Παράρτημα Α) διασφαλίζει ότι αρκεί η ανίχνευση της ανωμαλίας από έναν και μόνο αισθητήρα για να προστατευτεί ολόκληρο το δίκτυο, αποδεικνύοντας έμπρακτα την αξιοπιστία και την ανθεκτικότητα της προτεινόμενης μεθοδολογίας έναντι σε "αόρατες" απειλές.

Αξιολόγηση Απόδοσης Ανίχνευσης



Σχήμα 3: Αξιολόγηση απόδοσης (ROC Curves & Confusion Matrix) του μοντέλου

Όπως αποτυπώνεται στο παραπάνω γράφημα, το σύστημα επιτυγχάνει σχεδόν

απολύτως, με την Ακρίβεια (Precision) να αγγίζει το 0.998, την Ανάκληση (Recall) το απόλυτο 1.0 και το F1-Score το 0.999.

Σε αυτό το σημείο, εγείρεται εύλογα το ερώτημα εάν αυτά τα εξαιρετικά υψηλά αποτελέσματα είναι ενδεικτικά υπερεκπαίδευσης ή αντικατοπτρίζουν μια πλαστή πραγματικότητα ("too good to be true").

Η απάντηση βρίσκεται στον ίδιο τον πυρήνα της αρχιτεκτονικής, η οποία καθιστά την **υπερεκπαίδευση δομικά αδύνατη**.

Πρώτον, η μεθοδολογία είναι αυστηρά μη επιβλεπόμενη.

Το σύστημα δεν εκπαιδεύτηκε ποτέ πάνω σε κακόβουλα δεδομένα, συνεπώς είναι αδύνατον να απομνημόνευσε τις υπογραφές των επιθέσεων.

Δεύτερον, όπως αποδείχθηκε από την ανάλυση του χώρου καταστάσεων (Πίνακας 1), η σκόπιμη επιλογή της 1ης τάξης ($k=1$) λειτούργησε ως φυσικός διακόπτης, αποτρέποντας το σύστημα από το να απομνημονεύσει συγκεκριμένες, θορυβώδεις ακολουθίες πακέτων που θα οδηγούσαν σε υπερβολική συμμόρφωση.

Το απόλυτο 1.0 στο Recall (μηδενικά False Negatives) δεν οφείλεται στην ικανότητα ενός μεμονωμένου, υπερ-εκπαιδευμένου αλγορίθμου, αλλά στην αρχιτεκτονική του Multi-Sensor Fusion.

Το σύστημα λειτουργεί ως ένα πολυδιάστατο δίκτυο: εάν ένας επιτιθέμενος προσπαθήσει να μιμηθεί τη φυσιολογική κίνηση στο χαρακτηριστικό Flow Duration για να αποφύγει την ανίχνευση, θα προκαλέσει αναπόφευκτα έντονη ανωμαλία σε κάποιο άλλο χαρακτηριστικό (όπως το Total Forward Packets), πυροδοτώντας τον αντίστοιχο αισθητήρα.

Αντίστοιχα, η εντυπωσιακή Precision (0.998) πηγάζει από την ικανότητα του $k=1$ να διατηρεί επαρκή αβεβαιότητα ώστε να συγχωρεί τις φυσιολογικές -έστω και σπάνιες- διακυμάνσεις της υγιούς κίνησης, διατηρώντας τα False Positives σε πρακτικά μηδενικά επίπεδα.

6 Συζήτηση

6.1 Ερμηνεία Αποτελεσμάτων

Αν και τα πειραματικά αποτελέσματα ($F1\text{-Score} = 0.999$) αποδεικνύουν την εξαιρετική ικανότητα της αρχιτεκτονικής Multi-Sensor Fusion να διαχωρίζει την κακόβουλη από την υγιή κίνηση, η ορθή ερμηνεία τους απαιτεί την αναγνώριση των **εγγενών προκαταλήψεων** (biases) του συστήματος.

Η υψηλή απόδοση δεν συνεπάγεται την ανακάλυψη ενός "παγκόσμιου" κανόνα ανίχνευσης, αλλά υποδηλώνει ότι το μοντέλο έχει προσαρμοστεί απόλυτα (environment bias) στην τοπολογία και τις συνήθειες του συγκεκριμένου δικτύου στο οποίο εκπαιδεύτηκε.

Με άλλα λόγια, οι πίνακες μετάβασης της Μαρκοβιανής Αλυσίδας είναι άρρηκτα συνδεδεμένοι με το προφίλ του εκάστοτε οργανισμού.

Εάν το ίδιο -ήδη εκπαιδευμένο- μοντέλο εφαρμοζόταν σε ένα διαφορετικό εταιρικό δίκτυο, η απόδοσή του θα κατέρρεε, καθώς οι νέες υγιείς συμπεριφορές θα κατηγοριοποιούνταν λαθασμένα ως ανωμαλίες.

Συνεπώς, το προτεινόμενο σύστημα δεν προσφέρει ένα plug-and-play φίλτρο επιθέσεων, αλλά μια εξαιρετικά αποδοτική μεθοδολογία αυτο-εκμάθησης, η οποία απαιτεί **τοπική εκπαίδευση** για κάθε νέα υποδομή.

Επιπρόσθετα, το σύστημα φέρει την κλασική θεωρητική προκατάληψη της ανίχνευσης ανωμαλιών: την αυθαίρετη παραδοχή ότι «κάθε στατιστική απόκλιση ισοδυναμεί με επίθεση».

Σε ρεαλιστικές συνθήκες, ακραία αλλά νόμιμα γεγονότα, όπως μια μαζική αναβάθμιση λογισμικού ή μια απρόσμενη κορύφωση κίνησης λόγω τηλεργασίας, θα προκαλούσαν σημαντική απόκλιση της εντροπίας.

Παρόλο που ο σχεδιασμός των πολλαπλών αισθητήρων μετριάξει σε μεγάλο βαθμό αυτό το φαινόμενο, το σύστημα παραμένει από τη φύση του "προκατειλημμένο" υπέρ της ασφάλειας, προτιμώντας να σημάνει έναν Ψευδώς Θετικό συναγερμό από το να επιτρέψει μια ενδεχόμενη απειλή.

6.2 Περιορισμοί Συστήματος

Το σύστημα, παρόλη την επιτυχία του, παρουσιάζει τέσσερις κρίσιμους περιορισμούς που αξίζει να σημειωθούν:

1. **Απουσία Βαθιάς Επιθεώρησης:** Είναι πιο ορθό να παρέχεται υπηρεσία συνεργασίας μεταξύ ανάλυσης μεταδεδομένων και DPI. Στην προκειμένη, το σύστημα αναλύει αποκλειστικά μεταδεδομένα της κίνησης άρα επιθέσεις που γίνονται στο επίπεδο εφαρμογής και περιέχουν κακόβουλο κώδικα χωρίς να επηρεάζουν τον όγκο ή τη χρονική συμπεριφορά, είναι εντελώς αόρατες στο σύστημα.
2. **Επιθέσεις Αργού Ρυθμού (Low-and-Slow / APT):** Χρησιμοποιώντας $k = 1$, το σύστημα δεν έχει 'βαθιά μνήμη' για να πιάσει επιθέσεις που εξελίσσονται ύπουλα και αργά σε βάθος ημερών, με αναγκαστική απόρροια η διακύμανση να απορροφάται ως "φυσιολογική".
3. **Στατική και Offline Ανάλυση:** Το τρέχον σύστημα λειτουργεί ως post-mortem εργαλείο που αναλύει logs. Για να λειτουργήσει ζωντανά (σε real-time), πρέπει να διασυνδεθεί με εργαλεία παγίδευσης πακέτων όπως το libpcap.
4. **Ευνοιολογική Μετατόπιση (Concept Drift):** Η δικτυακή συμπεριφορά αλλάζει από δίκτυο και δίκτυο καθώς είναι και χρονικά μεταβαλλόμενη και εξαρτούμενη. Η στατική μήτρα μετάβασης καταστάσεων που δημιουργείται σήμερα θα γίνει παρωχημένη αύριο, απαιτώντας συνεχή εκπαίδευση ή ανανέωση του μοντέλου για να παραμένει επίκαιρη στο μέλλον.

Η επιλογή αυτών των περιορισμών ήταν ωστόσο **συνειδητή** προκειμένου να εγγυηθούμε την απόλυτη επεξηγησιμότητα. Αξίζει να σημειωθεί ότι η αρχιτεκτονική του συστήματος είναι πλήρως επεκτάσιμη και μπορεί να ενσωματώσει μελλοντικά επιπλέον αισθητήρες, όπως για παράδειγμα την ανάλυση DPI ή την παρακολούθηση συμπεριφοράς χρηστών (User Behavior Analytics), χωρίς να αλλοιώνεται η βασική φιλοσοφία της Μαρκοβιανής Αλυσίδας 1ης τάξης.

6.3 Πρόσθετες Λειτουργίες και Επεκτάσεις (BETA)

Προκειμένου το σύστημα ανίχνευσης να καταστεί απόλυτα προσβάσιμο σε πραγματικές συνθήκες (πέρα από το επίπεδο του ακατέργαστου κώδικα), στα πλαίσια της εργασίας αναπτύχθηκε επιπρόσθετα μια πειραματική Web εφαρμογή (Dashboard) βασισμένη στη βιβλιοθήκη Streamlit.

Το γραφικό αυτό περιβάλλον επιτρέπει σε αναλυτές ασφαλείας να οπτικοποιούν άμεσα τις τελικές μετρικές απόδοσης, να επιθεωρούν τα διαδραστικά γραφήματα απόκλισης της εντροπίας στο Timeline, αλλά και να εκτελούν "ζωντανά" μαθηματικές αποδείξεις της Θεωρίας Πληροφορίας πάνω στο dataset.

Μια από τις πιο ενδιαφέρουσες επεκτάσεις που ενσωματώθηκαν στο Dashboard, είναι η πρακτική εφαρμογή της **Κωδικοποίησης Huffman** ως δευτερεύοντος, ανεξάρτητου δείκτη ανίχνευσης επιθέσεων, βασιζόμενη στο Θεώρημα Κωδικοποίησης Πηγής του Shannon.

Σε κατάσταση κανονικής λειτουργίας, η δικτυακή κίνηση χαρακτηρίζεται από ποικιλομορφία και υψηλή εντροπία.

Κατά συνέπεια, ο αλγόριθμος Huffman επιτυγχάνει ένα μετριοπαθές ποσοστό συμπίεσης (π.χ. 2.71 μέσο όρο bits ανά σύμβολο).

Αντιθέτως, κατά τη διάρκεια μιας επίθεσης (π.χ. DDoS), το δίκτυο κατακλύζεται από εκατομμύρια επαναλαμβανόμενα, προβλέψιμα και δομικά πανομοιότυπα πακέτα. Αυτή η υπερβολική προβλεψιμότητα ισοπεδώνει την εντροπία της πηγής. Όταν ο αλγόριθμος Huffman επιχειρεί να συμπίεσει την κίνηση της επίθεσης, ο λόγος συμπίεσης αυξάνεται δραματικά και ο μέσος όρος bits ανά σύμβολο πέφτει ασυνήθιστα χαμηλά (π.χ. στο 2.30).

Αυτό το εξαιρετικά υψηλό ποσοστό συμπίεσης παράγει μια boolean ένδειξη (ή ένα κατώφλι συναγερμού) που πιστοποιεί μαθηματικά -και από μια εντελώς διαφορετική σκοπιά- την ύπαρξη κακόβουλης ρουτίνας στο δίκτυο, ενισχύοντας περαιτέρω την αξιοπιστία των Μαρκοβιανών Αλυσίδων.

7 Συμπεράσματα

7.1 Σύνοψη Εργασίας

Η χρήση Μαρκοβιανών αλυσίδων πρώτης τάξης και εντροπίας Shannon παρέχει μια αξιόπιστη, ελαφριά και πλήρως επεξηγήσιμη μέθοδο ανίχνευσης. Η αρχιτεκτονική Multi-Sensor ελαχιστοποιεί τα False Negatives και τα False Positives, καταπολεμώντας παράλληλα τις αδυναμίες κάθε αισθητήρα μεμονωμένα.

Σε μια εποχή όπου το Deep Packet Inspection καθίσταται δύσκολο λόγω της κρυπτογράφησης, η παρακολούθηση συμπεριφοράς βασισμένη στη Θεωρία της Πληροφορίας, παρά τους περιορισμούς που φέρει απέναντι σε επιθέσεις τεράστιας διάρκειας, αποτελεί μια σταθερή ασπίδα προστασίας. Ο εντοπισμός αποκλίσεων στο μοτίβο ανταλλαγής δεδομένων ανοίγει τεράστιους δρόμους για μελλοντικές live υλοποιήσεις.

7.2 Μελλοντική Εργασία

Αν και η παρούσα υλοποίηση αποδεικνύει την εγκυρότητα της προτεινόμενης μεθοδολογίας σε ελεγχόμενο περιβάλλον και στατικά σύνολα δεδομένων (offline datasets), ο απώτερος στόχος της έρευνας προσανατολίζεται στην ανάπτυξη ενός συστήματος ανίχνευσης πραγματικού χρόνου (real-time NIDS).

Η μετάβαση αυτή προϋποθέτει την αντικατάσταση της παρτίδας επεξεργασίας (batch processing) με μηχανισμούς συνεχούς ροής δεδομένων (data streaming), όπου το σύστημα θα παρακολουθεί τη δικτυακή κίνηση ζωντανά.

Σε ένα τέτοιο σενάριο προσομοίωσης πραγματικού δικτύου, ο υπολογισμός της εντροπίας και η αξιολόγηση των μεταβάσεων της Μαρκοβιανής Αλυσίδας θα πρέπει να εκτελούνται εντός αυστηρών χρονικών παραθύρων υπο-χιλιοστού του δευτερολέπτου, προκειμένου να διασφαλιστεί ότι η παρακολούθηση δεν θα εισάγει καθυστέρηση (latency) στην τοπολογία.

Επιπρόσθετα, ο σχεδιασμός του Multi-Sensor Fusion έχει δομηθεί εσκεμμένα με υψηλή επεκτασιμότητα, αφήνοντας γόνιμο έδαφος για μελλοντικό πειραματισμό

με πληθώρα νέων μεταβλητών.

Στα επόμενα στάδια της υλοποίησης, επιδιώκεται η ενσωμάτωση επιπλέον αισθητήριων μετρικών, τα οποία θα αντλούν πληροφορίες είτε από βαθύτερα επίπεδα του μοντέλου OSI (όπου η κρυπτογράφηση το επιτρέπει), είτε από χρονικές αποκλίσεις πολλαπλών πρωτοκόλλων.

Η προσθήκη νέων "αισθητήρων" στο ζωντανό περιβάλλον αναμένεται να πυκνώσει περαιτέρω το θεωρητικό "δίχτυ" προστασίας του συστήματος, μειώνοντας τα περιθώρια διαφυγής για έξυπνες, πολυμορφικές ή Zero-Day επιθέσεις, οι οποίες ενδεχομένως να προσπαθήσουν να μιμηθούν επιτυχώς τη συμπεριφορά της υγιούς κίνησης σε έναν ή δύο μεμονωμένους άξονες.

Αναφορές

- Ahmed, M., Mahmood, A. N., and Hu, J. (2016). A survey of network anomaly detection techniques. *Journal of Network and Computer Applications*, 60:19–31.
- Callegari, C., Giordano, S., and Pagano, M. (2009). On the use of compression algorithms for network anomaly detection. In *2009 IEEE International Conference on Communications*.
- Goodfellow, I., Bengio, Y., and Courville, A. (2016). *Deep learning*. MIT press.
- Lee, W. and Xiang, D. (2001). Information-theoretic measures for anomaly detection. In *Proceedings of the 2001 IEEE Symposium on Security and Privacy*, pages 130–143.
- Nychis, G., Sekar, V., Andersen, D. G., Kim, H., and Zhang, H. (2008). An empirical evaluation of entropy-based traffic anomaly detection. In *Proceedings of the 8th ACM SIGCOMM Conference on Internet Measurement*, pages 151–156.
- Shannon, C. E. (1948). A mathematical theory of communication. *Bell System Technical Journal*, 27(3):379–423.
- Ting, C., Field, R., Fisher, A., and Bauer, T. (2018). Compression analytics for classification and anomaly detection within network communication. *IEEE Transactions on Information Forensics and Security*.
- Ye, N., Ehiabor, T., and Zhang, Y. (2002). First-order versus high-order stochastic models for computer intrusion detection. *Quality and Reliability Engineering International*, 18(1):17–22.
- Ye, N., Zhang, Y., and Borrer, C. M. (2004). Robustness of the markov-chain model for cyber-attack detection. *IEEE Transactions on Reliability*, 53(1):116–121.
- Zervas, P. (2025). Βασικές Αρχές Θεωρίας Πληροφοριών. Διάλεξη 3.
- Zervas, P. (2026). Διακριτή Πηγή Πληροφορίας με Μνήμη. Διάλεξη 5.

A' Παράρτημα A: Κώδικας (Code Snippets)

Στο παρόν παράρτημα παρατίθενται τα σημαντικότερα αποσπάσματα κώδικα που υλοποιούν τους βασικούς αλγορίθμους του συστήματος ανίχνευσης. Ο πλήρης κώδικας βρίσκεται στα αντίστοιχα Jupyter Notebooks του έργου.

A.1 - Δυναδική Κωδικοποίηση Σημάτων TCP (Bitwise Encoding)

Ο παρακάτω κώδικας συνθέτει τις έξι διακριτές σημάσεις ελέγχου TCP (SYN, ACK, PSH, RST, URG, FIN) σε έναν μοναδικό ακέραιο αριθμό μέσω δυναδικής μάσκας (bitmask), παράγοντας ακριβώς 64 μοναδικές καταστάσεις (0-63).

```
1 # Synthesize 'TCP_Flags_Int' from individual flag columns
2 # Formula: SYN + 2*ACK + 4*PSH + 8*RST + 16*URG + 32*FIN
3 flag_cols = {
4     "SYN": "SYN Flag Cnt",
5     "ACK": "ACK Flag Cnt",
6     "PSH": "PSH Flag Cnt",
7     "RST": "RST Flag Cnt",
8     "URG": "URG Flag Cnt",
9     "FIN": "FIN Flag Cnt"
10 }
11
12 df = df.with_columns(
13     (
14         pl.col(flag_cols["SYN"]) * 1 +
15         pl.col(flag_cols["ACK"]) * 2 +
16         pl.col(flag_cols["PSH"]) * 4 +
17         pl.col(flag_cols["RST"]) * 8 +
18         pl.col(flag_cols["URG"]) * 16 +
19         pl.col(flag_cols["FIN"]) * 32
20     ).alias("TCP_Flags_Int")
21 )
```

Listing 1: TCP Flags Bitwise Encoding (data_pipeline.ipynb)

A.2 - Λογαριθμική Διακριτοποίηση Συνεχών Μεταβλητών (Log-Scale Binning)

Για τη μετατροπή των συνεχών χαρακτηριστικών σε διακριτές καταστάσεις, εφαρμόζεται πρώτα ο λογαριθμικός μετασχηματισμός $\log_{1p}(x) = \log(1 + x)$ για την εξομάλυνση των ακραίων τιμών, και ακολούθως Equal-Width Binning σε 8 κατηγορίες.

```
1 BINS = 8
2 numeric_cols = ["Flow_Duration", "Out_Degree",
3                 "Tot_Fwd_Pkts", "TotLen_Fwd_Pkts"]
4
5 # Compress extreme outliers using log transform
6 df_selected = df_selected.with_columns(
7     [pl.col(c).clip(lower_bound=0).log1p().alias(f"{c}_log")
8      for c in numeric_cols]
9 )
10
11 # Perform equal-width binning on the logged values
12 for col_name in numeric_cols:
13     col_log = f"{col_name}_log"
14     col_min = df_selected.select(pl.col(col_log).min()).item()
15     col_max = df_selected.select(pl.col(col_log).max()).item()
```

```

16
17     if col_max == col_min:
18         df_selected = df_selected.with_columns(
19             pl.lit(0).alias(f"{col_name}_sym")
20         )
21     else:
22         df_selected = df_selected.with_columns(
23             ((pl.col(col_log) - col_min) /
24              (col_max - col_min) * (BINS - 1))
25             .cast(pl.Int32)
26             .alias(f"{col_name}_sym")
27         )
28
29 # TCP Flags are already discrete (64 states)
30 df_selected = df_selected.with_columns(
31     pl.col("TCP_Flags_Int").cast(pl.Int32)
32     .alias("TCP_Flags_Int_sym")
33 )

```

Listing 2: Log-Scale Discretization (*data_pipeline.ipynb*)

A.3 - Κατασκευή Πίνακα Μεταβάσεων Μαρκοβιανής Αλυσίδας

Ο πυρήνας του αλγορίθμου εκπαίδευσης: σαρώνει μια ακολουθία συμβόλων, καταμετρά τις μεταβάσεις μεταξύ διαδοχικών καταστάσεων και κατασκευάζει τον Πίνακα Πιθανοτήτων Μετάβασης (Transition Probability Matrix) για οποιαδήποτε τάξη k .

```

1 from collections import defaultdict
2
3 SMOOTHING = 1e-9
4
5 def build_transition_matrix(sequence, k=1):
6     """Build a k-th order Markov chain transition
7     probability matrix from a symbol sequence."""
8     counts = defaultdict(lambda: defaultdict(int))
9     for i in range(len(sequence) - k):
10         state = str(tuple(sequence[i:i+k]))
11         nxt = str(sequence[i+k])
12         counts[state][nxt] += 1
13
14     prob = {}
15     for state, nexts in counts.items():
16         total = sum(nexts.values())
17         prob[state] = {s: c / total for s, c in nexts.items()}
18     return prob

```

Listing 3: Markov Chain Transition Matrix Builder (*training.ipynb*)

A.4 - Υπολογισμός Σταυροειδούς Εντροπίας (Cross-Entropy Loss)

Η συνάρτηση ανίχνευσης: δεδομένης μιας νέας ακολουθίας και του εκπαιδευμένου πίνακα μεταβάσεων, υπολογίζει τη μέση σταυροειδή εντροπία. Όταν μια μετάβαση δεν υπάρχει στο μοντέλο εκπαίδευσης, αντικαθίσταται με εξομάλυνση Laplace ($p = 10^{-9}$), εκτοξεύοντας την απόκλιση.

```

1 def window_cross_entropy(sequence, baseline_tm,
2                           k=1, smoothing=1e-9):
3     """Calculate the cross-entropy of a sequence given
4     the baseline transition matrix from training."""

```

```

5     if len(sequence) <= k:
6         return 0.0
7
8     log_prob_sum = 0.0
9     for i in range(len(sequence) - k):
10         state = str(tuple(sequence[i:i+k]))
11         nxt    = str(sequence[i+k])
12
13         # Get probability from baseline, else smoothing
14         if state in baseline_tm \
15             and nxt in baseline_tm[state]:
16             p = baseline_tm[state][nxt]
17         else:
18             p = smoothing # Laplace: ~29.9 bits penalty
19
20         log_prob_sum += -np.log2(p)
21
22     return log_prob_sum / (len(sequence) - k)

```

Listing 4: Cross-Entropy Loss Calculator (*detection.ipynb*)

A.5 - Βρόχος Ανίχνευσης Πολλαπλών Αισθητήρων (Multi-Sensor Fusion)

Ο κεντρικός βρόχος αξιολόγησης: σαρώνει τη δοκιμαστική κίνηση σε παράθυρα, υπολογίζει την κανονικοποιημένη απόκλιση κάθε αισθητήρα, και σημαίνει συναγερμό εφόσον έστω και ένας αισθητήρας υπερβεί το καθολικό κατώφλι (λογική πύλη OR).

```

1  for i in range(0, len(label_full) - window_size + 1,
2                stride):
3      is_alert = False
4      max_norm_dev = 0.0
5
6      for f in features:
7          seq_window = seqs[f][i : i + window_size]
8          ce = window_cross_entropy(
9              seq_window, models[f],
10             k=K_ORDER, smoothing=SMOOTHING
11         )
12         dev = abs(ce - base_H[f])
13
14         # Normalize: > 1.0 means threshold crossed
15         norm_dev = dev / thresh[f] if thresh[f] > 0 else 0
16         feature_deviations[f].append(norm_dev)
17
18         if norm_dev > 1.0:
19             is_alert = True # OR-gate logic
20         if norm_dev > max_norm_dev:
21             max_norm_dev = norm_dev
22
23     final_alerts.append(1 if is_alert else 0)

```

Listing 5: Multi-Sensor Fusion Detection Loop (*detection.ipynb*)